哈希表

@M了个J

https://github.com/CoderMJLee

http://cnblogs.com/mjios

码拉松

TreeMap分析

- 时间复杂度（平均）
  - 添加、删除、搜索：O(logn)

- 特点
  - Key 必须具备可比较性
  - 元素的分布是有顺序的

- 在实际应用中，很多时候的需求
  - Map 中存储的元素不需要讲究顺序
  - Map 中的 Key 不需要具备可比较性

- 不考虑顺序、不考虑 Key 的可比较性，Map 有更好的实现方案，平均时间复杂度可以达到 O(1)
  - 那就是采取哈希表来实现 Map

需求

- 设计一个写字楼通讯录，存放所有公司的通讯信息
  - 座机号码作为 key（假设座机号码最长是 8 位），公司详情（名称、地址等）作为 value
  - 添加、删除、搜索的时间复杂度要求是 O(1)

```
private Company[] companies = new Company[100000000];
public void add(int phone, Company company) {
    companies[phone] = company;
}
public void remove(int phone) {
    companies[phone] = null;
}
public Company get(int phone) {
    return companies[phone];
}
```

索引	数据
0	
1	
...	
40089008	小码哥
...	
68485438	大码哥
...	
99999999	

- 存在什么问题？
  - 空间复杂度非常大
  - 空间使用率极其低，非常浪费内存空间
  - 其实数组 `companies` 就是一个哈希表，典型的【空间换时间】

哈希表（Hash Table）

- 哈希表也叫做散列表（hash 有“剁碎”的意思）

- 它是如何实现高效处理数据的？

```
put("Jack", 666);
put("Rose", 777);
put("Kate", 888);
```

- 添加、搜索、删除的流程都是类似的

1. 利用哈希函数生成 key 对应的 index【O(1)】
2. 根据 index 操作定位数组元素【O(1)】

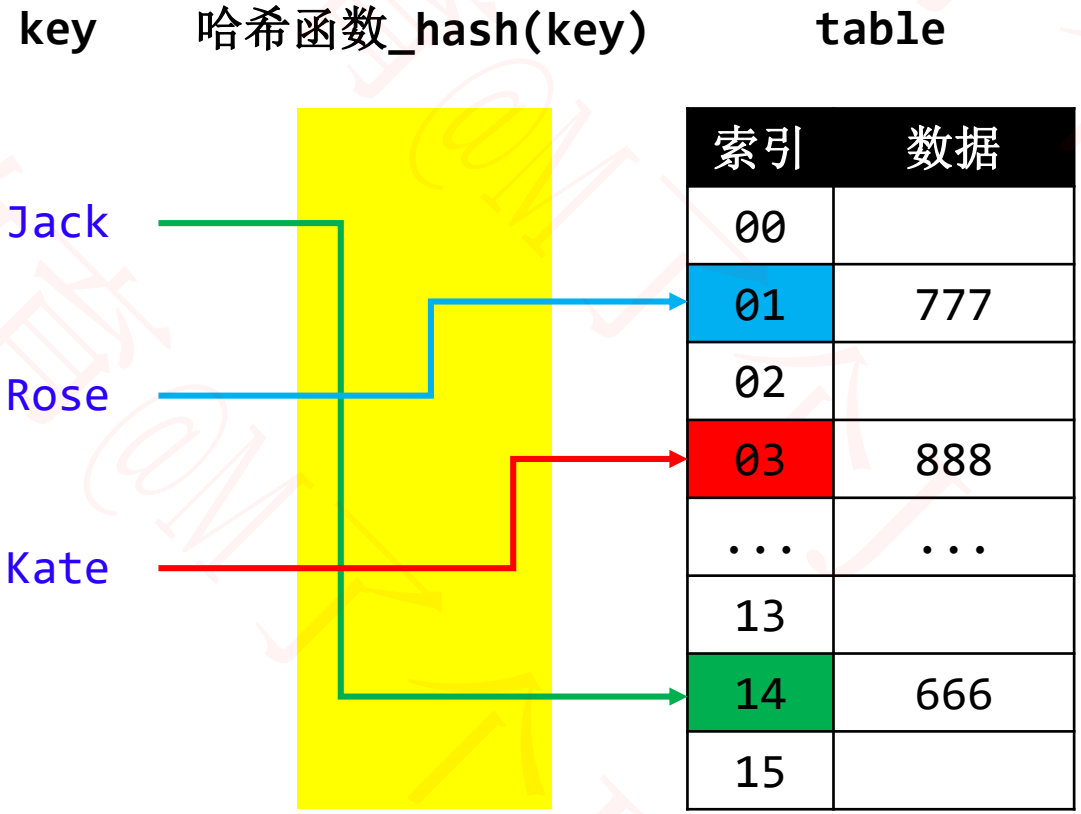

- 哈希表是【空间换时间】的典型应用
- 哈希函数，也叫做散列函数
- 哈希表内部的数组元素，很多地方也叫 Bucket（桶），整个数组叫 Buckets 或者 Bucket Array

哈希冲突（Hash Collision）

- 哈希冲突也叫做哈希碰撞
  - 2 个不同的 key，经过哈希函数计算出相同的结果
  - key1 ≠ key2 ，hash(key1) = hash(key2)

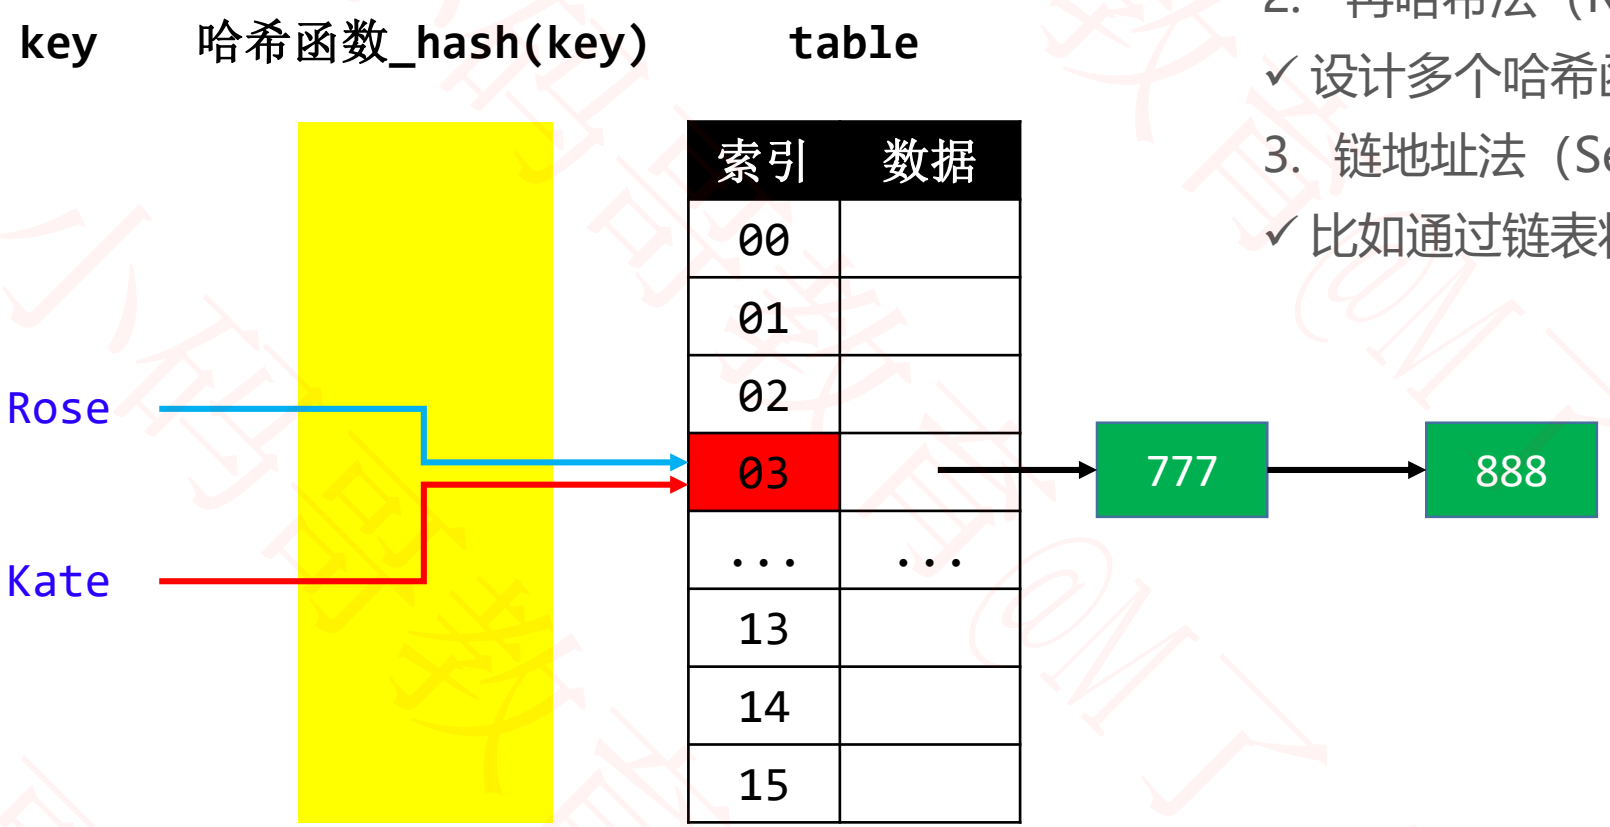

- 解决哈希冲突的常见方法

1. 开放定址法（Open Addressing）

✓ 按照一定规则向其他地址探测，直到遇到空桶

2. 再哈希法（Re-Hashing）

✓ 设计多个哈希函数

3. 链地址法（Separate Chaining）

✓ 比如通过链表将同一index的元素串起来

JDK1.8的哈希冲突解决方案

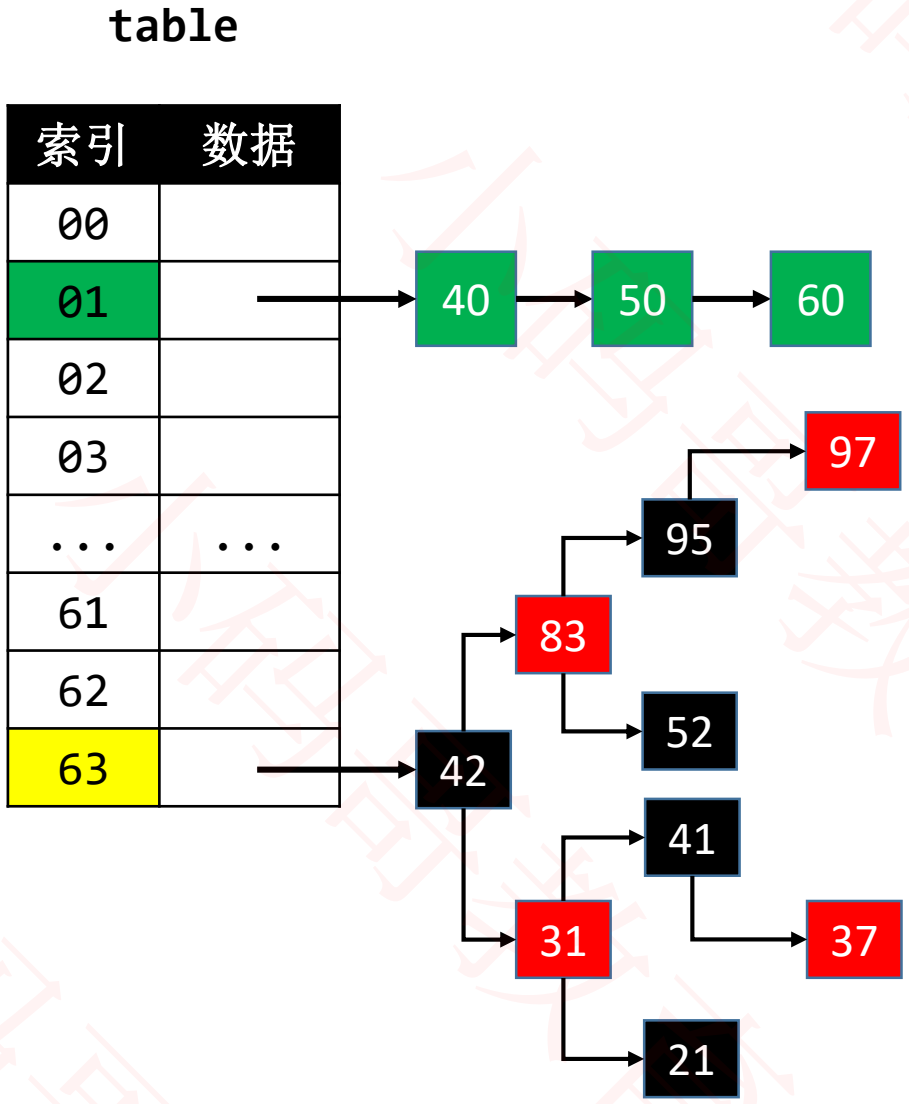

- 默认使用单向链表将元素串起来
- 在添加元素时，可能会由单向链表转为红黑树来存储元素
  - 比如当哈希表容量 ≥ 64 且 单向链表的节点数量大于 8 时
- 当红黑树节点数量少到一定程度时，又会转为单向链表
- JDK1.8中的哈希表是使用链表+红黑树解决哈希冲突
- 思考：这里为什么使用单链表?
  - 每次都是从头节点开始遍历
  - 单向链表比双向链表少一个指针，可以节省内存空间

哈希函数

■ 哈希表中哈希函数的实现步骤大概如下

1. 先生成 key 的哈希值（必须是整数）
2. 再让 key 的哈希值跟数组的大小进行相关运算，生成一个索引值

```
public int hash(Object key) {
    return hash_code(key) % table.length;
}
```

■ 为了提高效率，可以使用 & 位运算取代 % 运算【前提：将数组的长度设计为 2 的幂（2^n）】

```
public int hash(Object key) {
    return hash_code(key) & (table.length - 1);
}
```

1100 1010	1011 1100
& 1111	& 1111
1010	1100

■ 良好的哈希函数

□ 让哈希值更加均匀分布 → 减少哈希冲突次数 → 提升哈希表的性能

如何生成key的哈希值

- key 的常见种类可能有
  - 整数、浮点数、字符串、自定义对象
  - 不同种类的 key，哈希值的生成方式不一样，但目标是一致的
- ✓ 尽量让每个 key 的哈希值是唯一的
- ✓ 尽量让 key 的所有信息参与运算

- 在Java中，HashMap 的 key 必须实现 hashCode、equals 方法，也允许 key 为 `null`

- 整数
  - 整数值当做哈希值
  - 比如 10 的哈希值就是 10

```
public static int hashCode(int value) {
    return value;
}
```

- 浮点数
  - 将存储的二进制格式转为整数值

```
public static int hashCode(float value) {
    return floatToIntBits(value);
}
```

Long和Double的哈希值

```
public static int hashCode(long value) {
    return (int)(value ^ (value >>> 32));
}
```

```
public static int hashCode(double value) {
    long bits = doubleToLongBits(value);
    return (int)(bits ^ (bits >>> 32));
}
```

- >>> 和 ^ 的作用是?
  - 高32bit 和 低32bit 混合计算出 32bit 的哈希值
  - 充分利用所有信息计算出哈希值

value	1111 1111 1111 1111 1111 1111 1111 1111 1011 0110 0011 1001 0110 1111 1100 1010
value >>> 32	0000 0000 0000 0000 0000 0000 0000 0000 1111 1111 1111 1111 1111 1111 1111 1111
value ^ (value >>> 32)	1111 1111 1111 1111 1111 1111 1111 1111 0100 1001 1100 0110 1001 0000 0011 0101

字符串的哈希值

- 整数 5489 是如何计算出来的?
  - $5 * 10^3 + 4 * 10^2 + 8 * 10^1 + 9 * 10^0$

- 字符串是由若干个字符组成的
  - 比如字符串 jack，由 j、a、c、k 四个字符组成（字符的本质就是一个整数）
  - 因此，jack 的哈希值可以表示为 $j * n^3 + a * n^2 + c * n^1 + k * n^0$，等价于 $[(j * n + a) * n + c] * n + k$
  - 在JDK中，乘数 n 为 31，为什么使用 31?
    - ✓ 31 是一个奇素数，JVM会将 31 * i 优化成 (i << 5) – i

```
String string = "jack";
int hashCode = 0;
int len = string.length();
for (int i = 0; i < len; i++) {
    char c = string.charAt(i);
    hashCode = 31 * hashCode + c;
}
```

```
String string = "jack";
int hashCode = 0;
int len = string.length();
for (int i = 0; i < len; i++) {
    char c = string.charAt(i);
    hashCode = (hashCode << 5) - hashCode + c;
}
```

关于31的探讨

- 31 * i = (2^5 – 1) * i = i * 2^5 – i = (i << 5) – i

- 31不仅仅是符合2^n – 1，它是个奇素数（既是奇数，又是素数，也就是质数）
- 素数和其他数相乘的结果比其他方式更容易产成唯一性，减少哈希冲突
- 最终选择31是经过观测分布结果后的选择

小码哥教育 SEEMYGO

自定义对象的哈希值

```
public class Person {
    private int age;
    private float height;
    private String name;
    private Car car;
    @Override
    public int hashCode() {
        int hash = Integer.hashCode(age);
        hash = 31 * hash + Float.hashCode(height);
        hash = 31 * hash + name.hashCode();
        hash = 31 * hash + car.hashCode();
        return hash;
    }
    @Override
    public boolean equals(Object obj) {
        if (obj == this) return true;
        if (obj == null || obj.getClass() != getClass()) return false;
        Person person = (Person) obj;
        return person.age == age && person.height == height
                && valueEquals(person.name, name)
                && valueEquals(person.car, car);
    }
    private boolean valueEquals(Object v1, Object v2) {
        return v1 == null ? v2 == null : v1.equals(v2);
    }
}
```

- 思考几个问题
  - 哈希值太大，整型溢出怎么办？
  - ✓ 不用作任何处理

小码哥教育 SEEMYGO

自定义对象作为key

- 自定义对象作为 key，最好同时重写 hashCode 、equals 方法
  - equals ：用以判断 2 个 key 是否为同一个 key
    - ✓ 自反性：对于任何非 null 的 x，x.equals(x)必须返回true
    - ✓ 对称性：对于任何非 null 的 x、y，如果 y.equals(x) 返回 true，x.equals(y) 必须返回 true
    - ✓ 传递性：对于任何非 null 的 x、y、z，如果 x.equals(y)、y.equals(z) 返回 true，那么x.equals(z) 必须返回 true
    - ✓ 一致性：对于任何非 null 的 x、y，只要 equals 的比较操作在对象中所用的信息没有被修改，多次调用 x.equals(y) 就会一致地返回 true，或者一致地返回 false
    - ✓ 对于任何非 null 的 x，x.equals(null) 必须返回 false
  - hashCode ：必须保证 equals 为 true 的 2 个 key 的哈希值一样
  - 反过来 hashCode 相等的 key，不一定 equals 为 true

- 不重写 hashCode 方法只重写 equals 会有什么后果?
  - ✓ 可能会导致 2 个 equals 为 true 的 key 同时存在哈希表中

小码哥教育 SEEMYGO

哈希值的进一步处理：扰动计算

```
private int hash(K key) {
    if (key == null) return 0;
    int h = key.hashCode();
    return (h ^ (h >>> 16)) & (table.length - 1);
}
```

小码哥教育 SEEMYGO

装填因子

- 装填因子（Load Factor）：节点总数量 / 哈希表桶数组长度，也叫做负载因子

- 在JDK1.8的HashMap中，如果装填因子超过0.75，就扩容为原来的2倍

小码哥教育 SEEMYGO

TreeMap vs HashMap

- 何时选择TreeMap?
  - 元素具备可比较性且要求升序遍历（按照元素从小到大）

- 何时选择HashMap?
  - 无序遍历

LinkedHashMap

- 在HashMap的基础上维护元素的添加顺序，使得遍历的结果是遵从添加顺序的

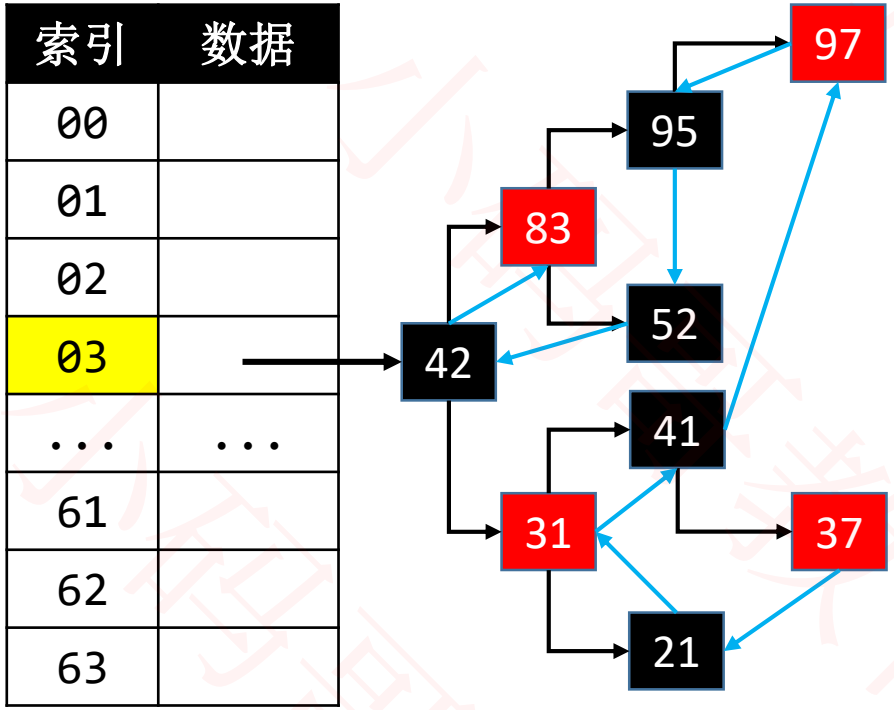

- 假设添加顺序是
  - 37、21、31、41、97、95、52、42、83

- 删除度为2的节点node时
  - 需要注意更换 node 与 前驱\后继节点 的连接位置

LinkedHashMap – 删除注意点

- 删除度为2的节点node时（比如删除31）
  - 需要注意更换 node 与 前驱\后继节点 的连接位置

索引	数据
00	
01	
02	
03	
...	...
61	
62	
63	

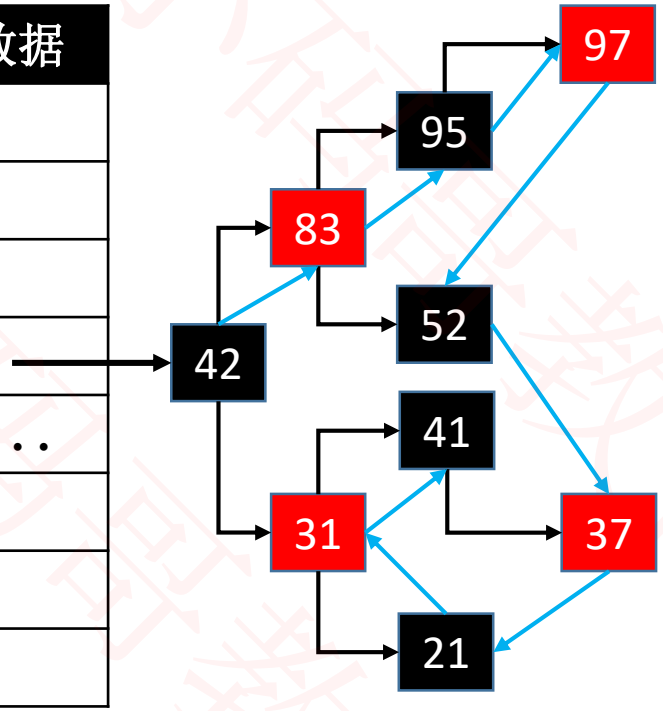

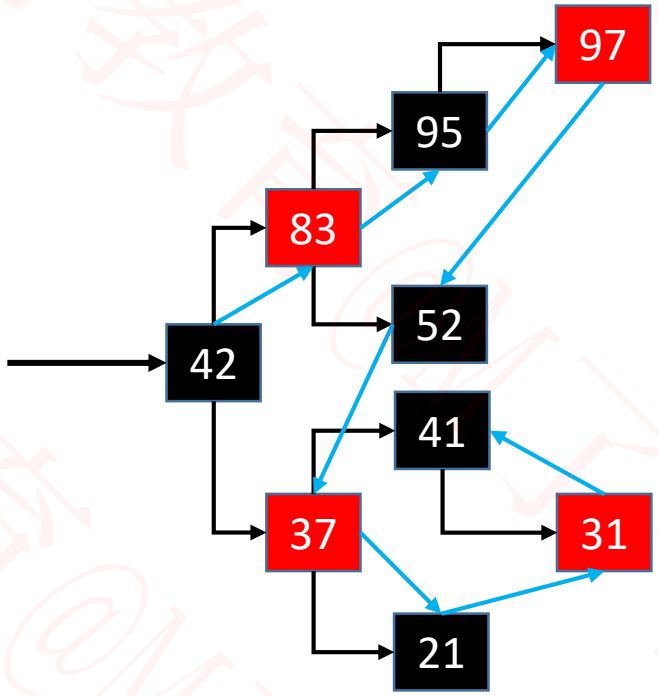

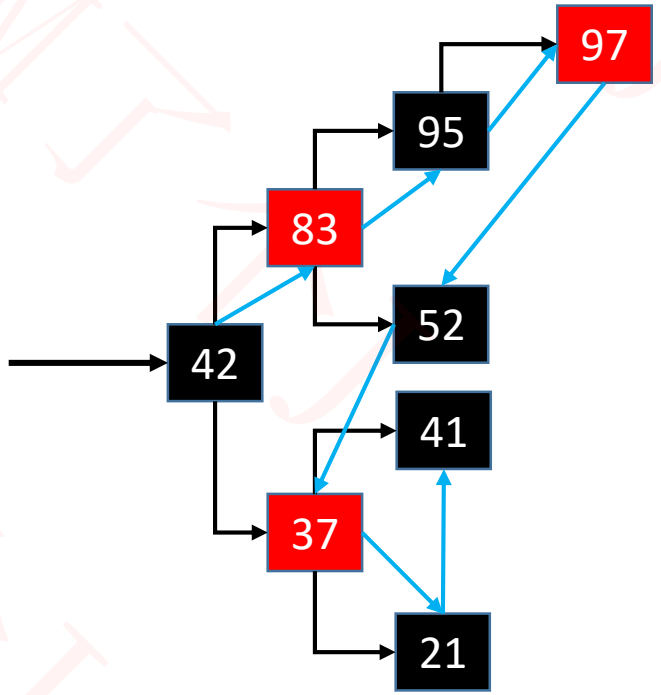

LinkedHashMap – 更换节点的连接位置


```
// 交换prev
LinkedNode<K, V> tmp = node1.prev;
node1.prev = node2.prev;
node2.prev = tmp;
if (node1.prev != null) {
    node1.prev.next = node1;
} else {
    first = node1;
}
if (node2.prev != null) {
    node2.prev.next = node2;
} else {
    first = node2;
}
```

```
// 交换next
tmp = node1.next;
node1.next = node2.next;
node2.next = tmp;
if (node1.next != null) {
    node1.next.prev = node1;
} else {
    last = node1;
}
if (node2.next != null) {
    node2.next.prev = node2;
} else {
    last = node2;
}
```

小码哥教育 SEEMYGO

关于使用%来计算索引

- 如果使用%来计算索引
  - 建议把哈希表的长度设计为素数（质数）
  - 可以大大减小哈希冲突

10%8 = 2	10%7 = 3
20%8 = 4	20%7 = 6
30%8 = 6	30%7 = 2
40%8 = 0	40%7 = 5
50%8 = 2	50%7 = 1
60%8 = 4	60%7 = 4
70%8 = 6	70%7 = 0

- 右边表格列出了不同数据规模对应的最佳素数，特点如下
  - 每个素数略小于前一个素数的2倍
  - 每个素数尽可能接近2的幂（2^n）

下界	上界	素数
2^5	2^6	53
2^6	2^7	97
2^7	2^8	193
2^8	2^9	389
2^9	2^{10}	769
2^{10}	2^{11}	1543
2^{11}	2^{12}	3079
2^{12}	2^{13}	6151
2^{13}	2^{14}	12289
2^{14}	2^{15}	24593
2^{15}	2^{16}	49157
2^{16}	2^{17}	98317
2^{17}	2^{18}	196613
2^{18}	2^{19}	393241
2^{19}	2^{20}	786433
2^{20}	2^{21}	1572869
2^{21}	2^{22}	3145739
2^{22}	2^{23}	6291469
2^{23}	2^{24}	12582917
2^{24}	2^{25}	25165843
2^{25}	2^{26}	50331653
2^{26}	2^{27}	100663319
2^{27}	2^{28}	201326611
2^{28}	2^{29}	402653189
2^{29}	2^{30}	805306457
2^{30}	2^{31}	1610612741